

# 人工智能应用与挑战实验

## 实验一 决策树实验

文泉

电子科技大学 计算机科学与工程学院

# 目录

- 1 信息熵、条件熵、信息增益的计算
- 2 ID3 算法—特征属性为连续值
- 3 准确率的计算公式
- 4 实验内容与要求

# 1. 信息熵、条件熵、信息增益的计算

► 首先对根节点，其信息熵为：

$$H(S) = - \sum_{i=1}^3 P(y_i) \log_2 P(y_i)$$

► 按 ID3 算法，需选择一个能使  $S$  的期望熵为最小的一个属性对根节点进行扩展，因此需先计算  $S$  关于每个属性的条件熵：

$$H(S|x_i) = \sum_t \frac{|S_t|}{|S|} H(S_t)$$

•  $t$  为属性  $x_i$  的属性值， $S_t$  为  $x_i = t$  时的例子集， $|S|$  和  $|S_t|$  分别是例子集  $S$  和  $S_t$  中元素的数目。

► 信息增益： $Gain(S, x_i) = H(S) - H(S|x_i)$

## 2. ID3 算法—特征属性为连续值

- ▶ ID3 算法就是在每次需要分裂时，计算每个属性的增益率，然后选择增益率最大的属性进行分裂。
- ▶ 对于特征属性为连续值，可如下使用 ID3 算法：
  - ① 先将  $S$  中元素按照第一个特征属性  $x_1$  排序，则每两个相邻元素的中间点可以看做潜在分裂点，从第一个潜在分裂点开始，分裂  $S$  并计算两个集合的期望信息，具有最小期望信息的点称为这个属性的最佳分裂点，其信息期望作为此特征属性  $x_1$  的信息期望。
  - ② 对其它所有特征属性  $x_i$  进行分裂后的信息期望计算。
  - ③ 选取信息增益最大的特征进行分裂。
  - ④ 直到决策树的各叶节点的信息熵为 0。

### 3. 准确率的计算公式

► 准确率的计算公式为：

$$accuracy = \frac{\text{total number of correct classified samples}}{\text{total number of testing samples}} \times 100\%$$

## 4. 实验内容与要求

### ▶ 实验内容：

- ① 利用 traindata.txt 的数据（75\*5，第 5 列为标签）进行训练，构造决策树。
- ② 利用构造好的决策树对 testdata.txt 的数据进行分类，并输出分类准确率。

### ▶ 实验要求：

- ① 提交源代码及可执行文件。
- ② 提交实验报告，内容包括：对代码的简单说明、运行结果的截图及说明等。
- ③ 需画出决策树，指明每个分支所对应的特征/属性，以及分裂值。
- ④ 注：如用到了剪枝、限定深度等技巧（加分项），请加以说明。